

基于机器学习和卫星遥感的中国小麦主产区播种面积监测

一、项目介绍

1.1 项目目的

在中国, 由于缺乏如同美国农业部(USDA)发布的农田数据层(CDL)和加拿大农业和农业食品部(AAFC)发布的作物清单(CI) 这种国家级中分辨率定期更新的作物类型地图, 想要获得能够覆盖较大空间范围并且可用于构建分类器的作物标签数据库和农业用地的详细地图是十分困难的。许多农业生产区缺乏可靠的中等分辨率作物特定地面参考, 无法用于直接训练现代、高效的监督学习模型。尽管随着观测卫星的发射, 卫星产品的空间和时间分辨率逐渐提高, 但作物类型标签的稀缺已成为生成大规模农田级作物地图的重大阻碍。地面数据标签的生成在很大程度上依赖于实地调查, 这是十分昂贵和费时费力的。一些研究通过视觉比较来自 GPS 记录和 Google Earth 的高分辨率 RGB 照片, 对遥感图像进行手动标记, 然而这种方法需要付出极大的人力物力, 对于大规模的监测项目是不可行的。

因此, 一个可行的解决方案是将已经训练有素的分类模型从具有完善的数据标签的区域转移到目标区域。按照这种思路, 我们选取了美国等地区, 从 USDA 官方网站获取作物数据标签, 通过建立 Random Forest(RF)、Neural Networks(NNs)、Support Vector Machine(SVM)和 Xgboost(XGB)等机器学习模型, 将美国农田数据作为训练集优化参数, 然后将其迁移至中国主要小麦种植区域进行测试, 以实现中国小麦主产区种植面积的监测。

1.2 现有研究

孟等^[1]提出了一种利用 MERIS 时间序列检测华北平原冬小麦关键物候期的方法。褚等^[2]利用 MODIS 时间序列提取了 2012-2013 年黄河三角洲冬小麦返青抽穗情况。尽管这些研究表明, 光学遥感对于大面积的物候提取来说是足够的, 但诸如云和霾污染等大气效应将始终存在, 并可能导致植被信息的很大不确定性。

为克服这些困难, 考虑使用合成孔径雷达^[3,4]。基于卫星的成像雷达, 如合成孔径雷达, 不受云层限制, 并有定期重访问隔。Sentinel-1 于 2014 年和 2016 年发射, 携带 C 波段合成孔径雷达传感器, 非常适合捕捉农业土地利用动态, 用于作物制图^[5]。Sentinel-1 是一种新的合成孔径雷达数据源, 具有更好的时空分辨率, 已用于作物监测和制图^[6-9]。例如, 纳瓦罗等人^[10]评估了光学和合成孔径雷达数据对作物类型分类(玉米、大豆、豆类和牧草)的互补性, 并估计了安哥拉每个物候期的长度。Muro 等人^[11]使用 S1-综合方法, 即 Sentinel-1 时间序列变化的检测方法, 捕捉湿地水面动态和农田农业实践产生的时空变化。此外, 合成孔径雷达时间序列也用于监测水稻和冬油菜的物候期^[12,13]。基于他们的发现, 我们的研究试图推广一种使用合成孔径雷达时间序列监测冬小麦的方法。

研究表明, 利用多时相遥感影像进行变化监测主要有 3 种方法:

- 1) 像元直接比较法。该方法对地物变化比较敏感, 可以避免图像分类所产生的误差, 但无法得到变化方向信息, 且对辐射校正要求很高。目前对各种噪声干扰(如传感器参数、物候差异等)产生的辐射差异的校正方法并不成熟, 只能通过选择同一传感器、同一季相数据来减少噪声, 导致像元直接比较法被局限在年际变化的研究上。另一方面, 不成熟的辐射校正导致大量伪变化, 变化与不变化的象元值产生大量重叠, 致使阈值确定困难。陈晋等提

出双窗口变步长阈值搜寻方法,从一定程度上解决了目视判断阈值所带来的效率问题与经验影响问题,提高了阈值确定的客观性,但并没有讨论阈值的敏感性对动态变化监测的影响。

2) 分类后比较法。该方法对辐射校正的要求较低,适用于不同传感器和不同季相数据的比较,并且可以确定类型变化的方向。但是多时相分类过程产生误差累积,严重影响了测量精度。Lichtenegger 等提出将多时相数据集成一个多波段数据集进行分类,避免了分类误差累积,但样本敏感性、类别划分复杂性增加,并且会产生大量低隶属度象元,单图像分类精度降低。

3) 混合法。该方法综合了象元直接比较法和分类后比较法各自的优点,正成为目前研究的热点之一,并有了一些成功的案例。Jenson 在监测湿地变化、何春阳在监测土地利用变化时,均利用象元直接比较法监测变化象元,再对多时相数据进行分类确定变化类型,研究表明该方法综合了象元直接比较法对变化敏感和分类后比较法可以得到变化类型信息的优点,提取精度优于传统方法;陈雪红等先对多时相数据进行分类,再对分类后验概率向量进行象元比较监测,通过变化向量的强度判定是否为变化象元,降低了多次分类带来的误差累积现象^[14]。

多时相卫星观测数据已被应用于机器学习模型的训练,包括决策树(DT)、随机森林(RF)、支持向量机(SVM)和多层感知器(MLP)(哈特米等人,2016年;King等人,2017年;lw等人,2013年;Massey等人,2017年;石、杨,2016)。

深度学习的最新进展表明,端到端神经网络方法可以从高维数据中发现复杂的关系(LeCun等人,2015年)。卷积神经网络(CNN)、递归神经网络(RNN)和具有位置编码的自注意力网络是三种突出的深度学习体系结构,能够高效地处理序列数据。已采用CNN从遥感影像中提取空间和光谱域的多级特征(黄等,2018;Kussul等人,2017年;Marcos等人,2018),但很少应用于时间序列分析的时域(钟等人,2019a,2019b)。RNN专门通过明确连接相邻的观测值来学习序列关系。RNN在处理诸如自然语言建模中的文本数据(Sundermeyer等人,2012年)和语音处理中的声学数据(Sak等人,2014年)等序列数据方面表现良好。在土地覆盖制图领域,一些研究利用从多时相遥感数据中识别时间特征(贾等人,2017年;Lyu等人,2016年;Mou等人,2019年)。自注意力结构在2017年被提出用于自然语言处理中的序列分析(Vaswani等人,2017)。它支持从超过10,000个单位的长序列中提取特征,并具有高效的并行计算能力^[15]。

1.3 项目意义

精确的作物制图为大规模作物产量估算的决策支持提供了重要而及时的信息。大多数现有的基于遥感数据和机器学习算法的特定作物覆盖产品,由于模型转换能力差,无法服务于大型农业生产区。因此,能够实现跨区域空间转移的作物分类模型是非常必要的。

可信和及时的作物制图对于监测作物种植与生长和评估农业资源以实现粮食安全至关重要。随着遥感技术的发展和数据量的增加,基于遥感数据的机器学习算法逐渐成为主流。本项目正是基于Sentinel-1卫星遥感数据的多模型对比与模型迁移研究,开创性地使用了Conv LSTM算法并且获得了可喜的结果,并且比较了多种模型的优势与劣势,能够为后续的研究排除多种错误的方向,同时也提供了全新的研究思路。

二、模型介绍

2.1 RandomForest 模型:

RandomForest 通过 Bagging 策略集成了多个决策树, 并通过 Bootstrap 重抽样的方法限制每次树分类时进入计算的特征数和样本数量, 使其有较好的泛化能力以及较低的时间复杂度, 而且具有较难过拟合的性质。所以在本项目中, RandomForest 被建立为基准模型, 用于与其他模型对比。在建立过程中, 我们测试了 `n_estimator`、`max_features`、`max_depth`、`min_samples_split` 参数的一系列可能取值后确定了最佳模型, 并将这个模型拟合训练数据来获得测试结果。

2.2 XGBoost 模型

2.2.1 概述

XGBoost 是一个优化的分布式梯度增强库, 旨在实现高效, 灵活和便携。它在 Gradient Boosting 框架下实现机器学习算法。XGBoost 提供了并行树提升 (也称为 GBDT, GBM), 可以快速准确地解决许多数据科学问题。相同的代码在主要的分布式环境 (Hadoop, SGE, MPI) 上运行, 并且可以解决超过数十亿个样例的问题。该库的目标是推动机器计算限制的极端, 以提供可扩展, 可移植和准确的库。XGBoost 成功背后最重要的因素是它在所有场景中的可扩展性, 该系统在单台机器上运行速度比现有流行解决方案快十倍以上, 并且在分布式或内存限制设置中可扩展至数十亿个示例。

2.2.2 原理

正则化学习目标:

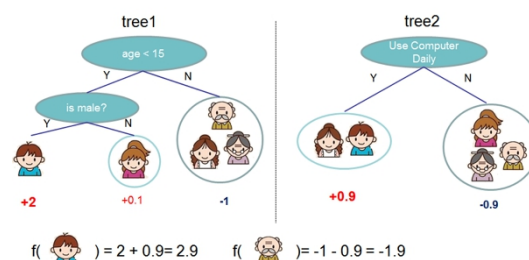


图 1 给定示例的最终预测是来自每棵树的预测总和。

对于一个给定的有 n 个样本和 m 个特征的数据集, 一个 tree ensemble model 使用 K 个累加的函数来预测输出:

$$\hat{y}_i = \phi(\mathbf{x}_i) = \sum_{k=1} f_k(\mathbf{x}_i), \quad f_k \in \mathcal{F} \quad (1)$$

$$F = f(x) = w_{q(x)}(q: \mathbb{R} \rightarrow T, w \in \mathbb{R}^T)$$

其中 \mathcal{F} 是 CART (回归树) 的空间。 q 代表每个树的结构, 其可以将每个样本映射到对应的叶节点中, T 是树中叶子节点的个数。每个 f_k 对应于一个独立的树结构 q 和叶子权重 w 。不同于决策树, 每个回归树在每一个叶节点上包含一个连续分数值, w_i 代表第 i 个结点的分

数。对于每个样本，我们将使用多个树中决策规则来将它分类到叶节点中，并且通过累加对应叶子中的分数 w 来获得最终的预测(每个样本的预测结果就是每棵树预测分数的总和)。，为了学习模型中使用的函数集合，我们最小化下列正则化目标：

$$\mathcal{L}(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k)$$
$$\text{where } \Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|^2$$

其中 l 是一个可微凸损失函数，度量预测值与目标值之间的差。第二项惩罚模型的复杂度（所有回归树的复杂度之和）。该项中包含了两个部分，一个是叶子结点的总数，一个是叶子结点得到的 L2 正则化项。这个额外的正则化项能够平滑每个叶节点的学习权重来避免过拟合。直观地，正则化的目标将倾向于选择采用简单和预测函数的模型。当正则化参数为零时，这个函数就变为传统的 gradient tree boosting。

收缩（Shrinkage）和列特征抽样（Column Subsampling）：

除了正则化目标，xgboost 还另外使用了两种技术来进一步防止过度拟合。第一种技术是收缩（Shrinkage），在 tree boosting 的每个步骤之后，收缩比例通过因子 η 新增加权重。与随机优化中的学习速率类似，shrinkage 降低了每棵独立树的影响，并为将来的树木留出了空间来优化模型。

第二种技术是列特征抽样（Column Subsampling）。这种技术通常用于 RandomForest，但以前没有应用于 tree boosting。根据用户反馈，使用列抽样比传统的行抽样（也支持）更加能够防止过度拟合，而且还加速了并行算法的计算。

2.2.3 总结

XGBoost 是一个可扩展的 tree boosting 系统，被数据科学家广泛使用，并提供了许多问题的最新结果。xgboost 运用了一种用于处理稀疏数据的新颖稀疏感知算法，和用于近似学习的理论上合理的加权分位数草图（weighted quantile sketch）。缓存访问模式，数据压缩和分片是构建可扩展的端到端系统以实现 tree boosting 的基本要素。通过结合这些要素，XGBoost 能够使用最少量的资源解决现实世界的规模问题。

项目通过建立 XGBoost 模型，将美国农田数据以 98: 1: 1 的比例分割为 training set, development set, test set，分别进行模型的训练、测试和评估。经过调参后，XGBoost 模型在测试时获得 91% 的精度。进一步，我们通过 XGBoost 模型对以下五个地点基于 2015-2018 的数据进行训练，并用 2019 年数据进行预测，以验证模型的时间可靠性，获得一定的数据结果；并利用 Sumner KS 2015-2018 的数据进行训练，再分别以其他四个地点进行测试，以验证模型的空间可靠性，获得一定的测试结果。

2.3 WheatMappingModel（WMM）模型

WheatMappingModel(WMM)模型的输入是预处理后的遥感图像，输出是图像每个像素是否种植冬小麦，输出 1 代表种植的是冬小麦，输出 0 代表种植的不是冬小麦。模型使用了 4 层 Conv-LSTM 以及感知机来学习遥感图像的时序特征和空间特征。总的来说，模型分为

四个模块：输入模块、Conv-LSTM 模块、感知机模块、输出模块。

2.3.1 输入模块：

原始遥感图像的维度为(Channels, Height, Width),在本项目中遥感图像含有两个通道。在输入模块中，我们把同一个地点遥感图像的 12 个时间点的数据堆叠起来，将堆叠后维度为 (Timestep, Channels, Height, Width)的图像输入网络。

2.3.2 Conv-LSTM 模块：

在本项目中，我们采用了四层 Conv-LSTM 来提取遥感图像的时间和空间信息，每一层 Conv-LSTM 由一个 Conv-LSTM 单元构成。Conv-LSTM 是卷积神经网络 CNN 与循环神经网络 LSTM 结合构成的，由 Shi 等人^[16]在 2015 年发表的名为 Convolutional LSTM Network: A Machine Learning Approach for Precipitation Nowcasting 的文章中提出的。在该文章中，作者将模型应用于短时降雨预测问题，文中实验表明，在这类问题中，Conv-LSTM 网络能够很好地捕捉时空相关性，并始终优于 FC-LSTM。因为我们所处理的冬小麦种植区域预测问题与文章中的问题有异曲同工之处，也是一个时空预测的问题，故选择尝试将 Conv-LSTM 应用到本网络中。

LSTM: LSTM 是 RNN 的一种变体。在 LSTM 中，第 t 个时间步的信息被选择性地传输到下一个时间步 $t+1$ 中。LSTM 采用了“门”结构来实现这种选择性，可以控制 LSTM 保留当前时间步的程以及传入下一个时间步的程度，每次有新的输入输入时，如果输入门被激活，则其信息将基类到单元中，此外如果遗忘门 f_t 开启，则过去单元的状态会被遗忘。更进一步，是否将最新的单元输出 c_t 传播到最终状态 h_t 是通过输出门。这种设计使得 LSTM 相比于普通的 RNN 可以更好学习长依赖关系，更有利于处理时间序列信息。下列为 LSTM 的一些重要方程（其中 \odot 代表 Hadamard 乘积）：

$$\begin{aligned} i_t &= \sigma(W_{xi}x_t + W_{hi}h_{t-1} + W_{ci} \odot c_{t-1} + b_i) \\ f_t &= \sigma(W_{xf}x_t + W_{hf}h_{t-1} + W_{cf} \odot c_{t-1} + b_f) \\ c_t &= f_t \odot c_{t-1} + i_t \odot \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \\ o_t &= \sigma(W_{xo}x_t + W_{ho}h_{t-1} + W_{co} \odot c_t + b_o) \\ h_t &= o_t \odot \tanh(c_t) \end{aligned}$$

Conv-LSTM: LSTM 在各个状态之间使用了全连接的设计，输入向量也是一维的时间序列，无法体现空间上的关联性。而 Conv-LSTM 中所有的输入 X_1, X_2, \dots, X_t ，单元输出 C_1, C_2, \dots, C_t ，隐藏状态 H_1, H_2, \dots, H_t 都是三维向量，在输入到状态以及状态之间的转换中都使用了卷积操作。这种设计使得 Conv-LSTM 网络中某个单元的未来状态，取决于其在图像中相邻单元的输入和其本身的过去状态，这种方式使得 Conv-LSTM 能同时提取时间和空间的信息，下面是 Conv-LSTM 中的一些重要方程（其中 '*' 表示卷积算符，而 ' \odot ' 像之前一样表示 Hadamard 乘积）：

$$\begin{aligned}
i_t &= \sigma(W_{xi} * \mathcal{X}_t + W_{hi} * \mathcal{H}_{t-1} + W_{ci} \odot \mathcal{C}_{t-1} + b_i) \\
f_t &= \sigma(W_{xf} * \mathcal{X}_t + W_{hf} * \mathcal{H}_{t-1} + W_{cf} \odot \mathcal{C}_{t-1} + b_f) \\
\mathcal{C}_t &= f_t \odot \mathcal{C}_{t-1} + i_t \odot \tanh(W_{xc} * \mathcal{X}_t + W_{hc} * \mathcal{H}_{t-1} + b_c) \\
o_t &= \sigma(W_{xo} * \mathcal{X}_t + W_{ho} * \mathcal{H}_{t-1} + W_{co} \odot \mathcal{C}_t + b_o) \\
\mathcal{H}_t &= o_t \odot \tanh(\mathcal{C}_t)
\end{aligned}$$

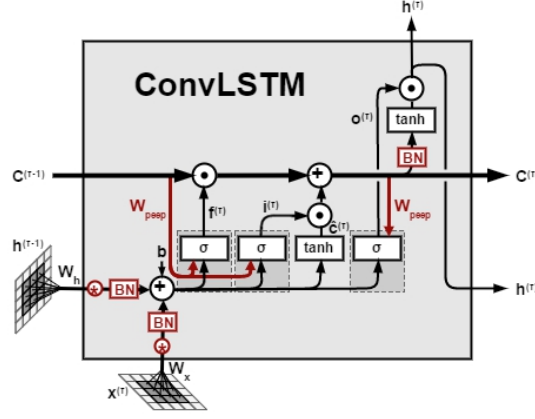


图 2 Conv-LSTM 单元示意图

2.3.3 感知机模块:

为了更好地汇总来自多个时间步长的信息以进行作物类型分类, 我们通过归一化的权重参数调整每个隐藏特征对输出模块的贡献。感知机模块由具有 Softmax 功能的一层全连接网络组成, 它为从 Conv-LSTM 模块获得的每个隐藏特征向量 h_t 生成权重值 α_t 。对于每个时间步长 t , 通过等式计算调整后的隐藏特征 h_t^*

$$\begin{aligned}
\alpha_t &= \text{softmax}(W_{\text{attention}} \cdot h_t + b_{\text{attention}}) \\
h_t^* &= \alpha_t h_t
\end{aligned}$$

其中 $W_{\text{attention}}$ 和 $b_{\text{attention}}$ 是两个可学习的权重矩阵且在所有时间步中共享, Softmax 用来归一化权重值 α_t , 以使得所有权重值的和为 1. 将所有的调整后的隐藏特征向量相加, 以生成整个时间序列的最终表示形式。对于每一个像素, 模块的输出为 $\sum_{i=1}^T h_i^*$ 。

2.3.4 输出模块:

这个模块会输出每个像素的是冬小麦的概率以及根据下面的法则对每个像素进行分类。

$$\begin{aligned}
\text{Sigmoid}(\text{Probability}) > 0.5 \quad \text{pred} = 1 \\
\text{Sigmoid}(\text{Probability}) \leq 0.5 \quad \text{pred} = 0
\end{aligned}$$

其中, Probability 指的是感知机模块的输出, 即每个像素是冬小麦的概率, 分类为 1 表示这个像素种植的是冬小麦, 分类为 0 代表种植的不是冬小麦。

在这个模块中, 我们使用了 Binary Cross Entropy 来计算输出 x 和实际值 y 之间的损失函数:

$$Loss = \frac{1}{N} \sum_{i=1}^N [p_c y_{n,c} \cdot \log Sigmoid(x_{n,c}) + (1 - y_{n,c}) \cdot \log(1 - Sigmoid(x_{n,c}))]$$

其中 p_c 值是用来平衡样本，增加在小样本在损失函数中权重，我们将 p_c 定义为
 $\frac{\text{不是冬小麦的像素总数}}{\text{是冬小麦的像素总数}}$ ，其效果相当于将一个不平衡的数据集转化为正反例都是 1:1 的平衡数据集

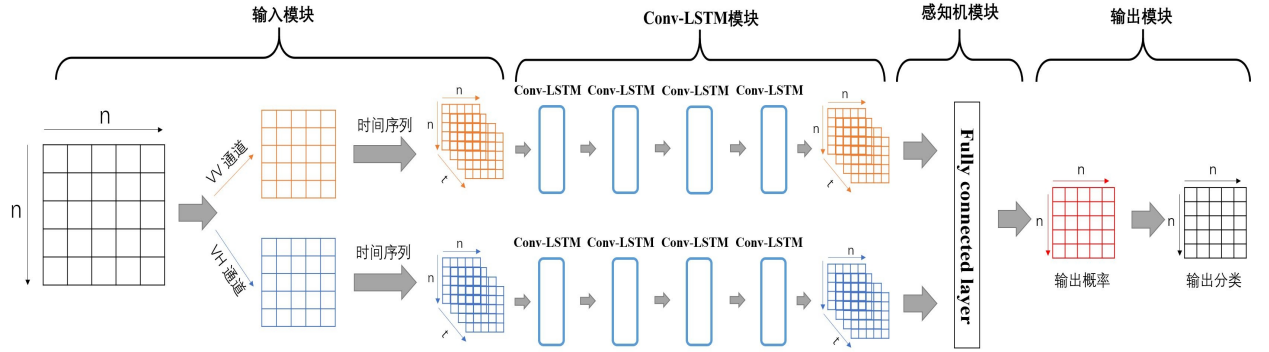


图 3 WheatMappingModel 模型结构图

三、实验步骤：

3.1 数据获取：

我们通过 USDA 的统计数据在美国的冬小麦种植区挑选了 5 个遥感数据充足且种植冬小麦面积较大的县，分别将它们命名为地点 A、B、C、D、E。

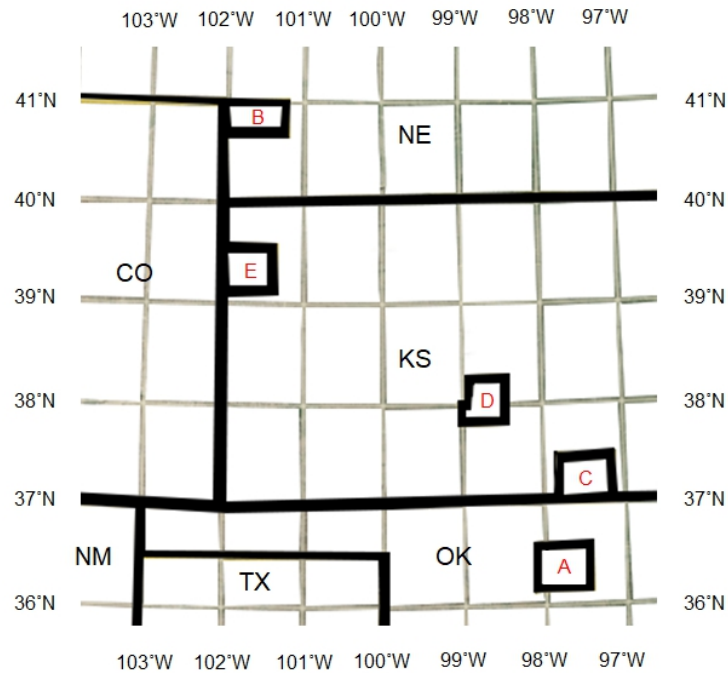


图 4 五个 county 在地图上的位置示意图 (A: Garfield, Oklahoma; B: Perkins, Nebraska; C: Sumner, Kansas; D: Stafford, Kansas; E: Sherman, Kansas)




图 5 时间序列构建示意图

我们从 Google Earth Engine 下载 Sentinel-1 SAR GRD 卫星数据，并选取其中的 VV/VH 波段，经过地形矫正，Refined Lee 滤波、去除缺失值后用来构建时间序列图像。为了构建时间序列图像，我们从 9 月 10 日开始，24 天作为一个时间间隔，共取 12 个时间间隔以跨越整个冬小麦播种-收获的时期。我们把每个时间间隔内所有图像取平均值，作为这个时间间隔的图像数据，最终获得了一个有 12 个时间步的时间序列卫星图像。同时获取当年的 CDL 数据作为数据标签。对地点 A、B、C、D、E 的 2015-2019 年分别构建时间序列卫星图像，就获得了全部的模型输入。

表 1 各地点数据信息统计表

地点	名称	county code	年份	有效像素个数	冬小麦的像素个数	冬小麦种植占比
A	Garfield	40047	2015	312183	147092	47.12%
			2016	3040719	1269971	41.77%
			2017	3040663	1141202	37.53%
			2018	3040704	1266071	41.64%
			2019	3040584	1297853	42.68%
B	Perkins	31135	2015	2267308	329102	14.52%
			2016	2535421	423319	16.70%
			2017	2535322	357536	14.10%
			2018	2535404	330768	13.05%
			2019	2535278	339157	13.38%
C	Sumner	20191	2015	3399014	1356267	39.90%
			2016	3399419	1319334	38.81%
			2017	3399299	1093271	32.16%
			2018	3399449	1119960	32.95%
			2019	3399291	991205	29.16%
D	Stafford	20185	2015	2278515	639117	28.05%
			2016	2278424	568085	24.93%
			2017	2278453	562709	24.70%
			2018	2278571	607031	26.64%
			2019	2278351	544496	23.90%
E	Sherman	20181	2015	918670	221169	24.07%
			2016	918640	219407	23.88%
			2017	917480	218990	23.87%
			2018	915226	209434	22.88%
			2019	917163	172306	18.79%

对于 XGBoost 和 RandomForest 模型，我们将获取的时间序列图像和数据标签压缩到二维后输入模型，一个维度代表的是图像总的像素数量，另一个维度是图像的特征。图像共有 2 个通道*12 个时间步的特征，总共 24 个特征。对于 WMM 模型，我们将获取的图像随机抽样，每一年每一个地点随机抽取 200 幅 128*128 像素的子图，再从相应年的 CDL 图像中裁剪下对应的标签。这些子图和标签就是 WMM 模型的全部输入。(预处理后的数据集：

<https://drive.google.com/drive/folders/1gmKLUNIITBMyPad3d7YRojixsZSGk6pQ?usp=sharing>)

3.2 实验设计

为了测试模型的精度以及迁移能力，我们设计并执行了两种测试：本地测试和空间迁移测试。本地测试是以当地 2015-2018 年的数据作为训练集，将 2019 年的数据作为测试集测试。空间迁移测试则是选定一个本地测试结果最好的地点作为基准地点，以该地点 2015-2018 年的数据作为训练集，以其他四地的 2019 年的数据分别作为测试集测试。本地测试用来考察模型的在时间维度上的预测能力，空间迁移测试则考察的是模型的空间迁移能力。

所有的数据预处理以及模型建立过程都是在 Google Colab 服务器上完成，模型均使用 Python 构建，其中 WMM 模型是由 Pytorch 库构建，RandomForest 和 XGBoost 模型都是由 Scikit-learn 库构建。

模型采用总体准确度和 F1 得分两个评估指标，总体准确度可以整体考量模型精度，但是由于项目中使用的样本并不均匀（非冬小麦的样本比冬小麦的样本多很多），所以使用 F1 得分来考量各个类别样本分类情况。下列就是总体准确度和 F1 得分的计算方法。

TP (True Positive)：正确预测为本类

FP (False Positive)：错将其他类预测为本类

FN (False Negative)：本类标签预测为其他类标

TN (True Negative)：正确预测为非本类

$$\text{准确度 (accuracy)} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{precision} = \frac{TP}{TP + FP}$$

$$\text{recall} = \frac{TP}{TP + FN}$$

$$F1 = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$

四、结果与分析：

4.1 本地测试:




图 6 三种模型（WheatMappingModel、XGBoost、RandomForest）在五个地点本地测试的准确度值统计




图 7 三种模型（WheatMappingModel、XGBoost、RandomForest）在五个地点本地测试的 F1 得分统计

分析图 1 可得，在本地测试中，三种模型都有较高的准确度，且模型之间准确度差距不大，相较之下 RandomForest 模型准确度略高一些。但是在 F1 得分上，WMM 模型要远高于其他两种模型。分析原因，一是 F1 得分相比与准确度，更能体现正样本的预测精度，而在表 1 中不难发现，在这四个地点种植冬小麦的像素都是小于不种植冬小麦的像素个数的，也就是正样本数小于负样本数。而 WMM 的损失函数中加入了 p_c 来平衡样本，使得模型不受不平衡训练集的影响，因而获得较高 F1 得分。二是 WMM 能同时提取时间空间信息，能够更好的学习训练集中的特征。

4.2 空间迁移测试：




图 8 三种模型（WheatMappingModel、XGBoost、RandomForest）以地点 C 为基准地点，迁移到其他四个地点的空间迁移测试准确度值统计




图 9 三种模型（WheatMappingModel、XGBoost、RandomForest）以地点 C 为基准地点，迁移到其他四个地点的空间迁移测试准确度值统计

综合分析图 1、2，WMM 的空间迁移性能相比其他两个更加突出，尤其体现在 F1 测试得分上。这说明 WMM 模型有较好的泛化能力以及更好的空间迁移性能。

五、总结与展望：

本次项目主要测试了三种模型监测冬小麦种植面积的能力。可以看到，基于 Conv-LSTM 的 WMM 模型有着不错的研究前景。但是整体来看，WMM 模型的精度还有很大的提升空间。我们经过分析得出模型还有以下几个可能的优化方向。

1. 增加特征数量。在本项目中，只采用了 VV,VH 两个通道的数据作为特征，后续还可以从高光谱卫星中加入一些波段以增加特征数量，或许能提高模型的精度。

2. 优化模型结构，自从 Shi^[16]于 2015 年发表了 Conv-LSTM 模型来解决时空预测问题后，其他学者也研究并提出了许多基于 Conv-LSTM 的优化模型。比如说 Wang 等^[17]在 2017 年提出的 PredRNN，解决了 Conv-LSTM 并行堆叠之后层与层之间是独立的，抽取空间特征会影响到时间信息的传播的问题。

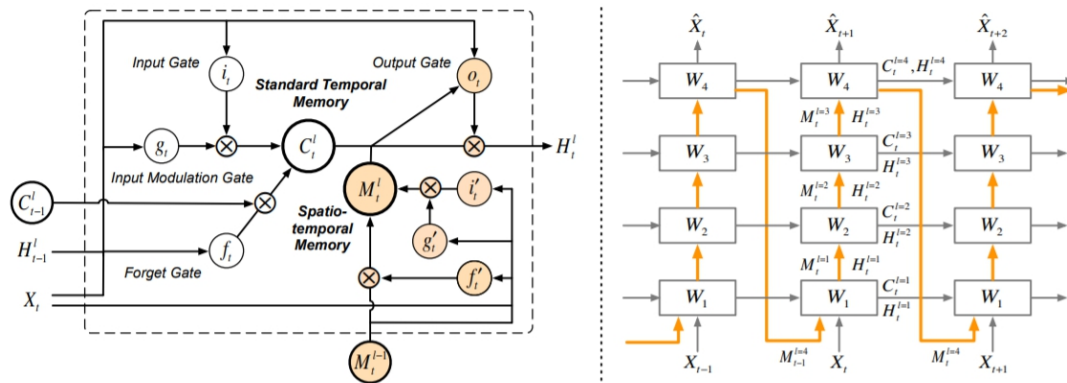


图 10 右边是 PredRNN 单元，左边白色部分是普通的 Conv-LSTM 单元，橙色的线条表示的是 PredRNN 相比 Conv-LSTM 新增的时空信息传递流

3. 选用分类概率标签。在本项目中，我们选用的标签是 USDA 提供的 CDL 分类标签，也可以尝试采用 CDL 分类概率标签，提高损失函数的准确度。

参考文献

- [1]Meng, J.H.; Wu, B.F.; Li, Q.Z.; Du, X.; Jia, K. Monitoring crop phenology with MERIS data—A case study of winter wheat in North China Plain. In Proceedings of the Electromagnetics Research Symposium, Beijing, China, 23–27 March 2009; pp. 1225–1228.
- [2]Chu, L.; Huang, C.; Liu, Q.S.; Liu, G.H. Estimation of winter wheat phenology under the influence of cumulative temperature and soil salinity in the Yellow River Delta, China, using MODIS time-series data. Int. J. Remote Sens. 2016, 37, 2211–2232. [CrossRef]
- [3]Ruetschi, M.; Schaepman, M.E.; Small, D. Using Multitemporal Sentinel-1 C-band Backscatter to Monitor Phenology and Classify Deciduous and Coniferous Forests in Northern Switzerland. Remote Sens. 2018, 10, 55. [CrossRef]
- [4]Steele-Dunne, S.C.; McNairn, H.; Monsivais-Huertero, A.; Judge, J.; Liu, P. W.; Papathanassiou, K. Radar

- Remote Sensing of Agricultural Canopies: A Review. *IEEE J. Sel. Top. Appl. Earth Obs. Remote Sens.* 2017, 10, 2249–2273. [CrossRef]
- [5] Bargiel, D. A new method for crop classification combining time series of radar images and crop phenology information. *Remote Sens. Environ.* 2017, 198, 369–383. [CrossRef]
- [6] Clauss, K.; Ottinger, M.; Leinenkugel, P.; Kuenzer, C. Estimating rice production in the Mekong Delta, Vietnam, utilizing time series of Sentinel-1 SAR data. *Int. J. Appl. Earth Obs.* 2018, 73, 574–585. [CrossRef]
- [7] Steinhausen, M.J.; Wagner, P.D.; Narasimhan, B.; Waske, B. Combining Sentinel-1 and Sentinel-2 data for improved land use and land cover mapping of monsoon regions. *Int. J. Appl. Earth Obs.* 2018, 73, 595–604. [CrossRef]
- [8] Van Tricht, K.; Gobin, A.; Gilliams, S.; Piccard, I. Synergistic Use of Radar Sentinel-1 and Optical Sentinel-2 Imagery for Crop Mapping: A Case Study for Belgium. *Remote Sens.* 2018, 10, 1642. [CrossRef]
- [9] Gao, Q.; Zribi, M.; Escorihuela, M.J.; Baghdadi, N.; Segui, P.Q. Irrigation Mapping Using Sentinel-1 Time Series at Field Scale. *Remote Sens.* 2018, 10, 1495. [CrossRef]
- [10] Navarro, A.; Rolim, J.; Miguel, I.; Catalao, J.; Silva, J.; Painho, M.; Vekerdy, Z. Crop Monitoring Based on SPOT-5 Take-5 and Sentinel-1A Data for the Estimation of Crop Water Requirements. *Remote Sens.* 2016, 8, 525. [CrossRef]
- [11] Muro, J.; Canty, M.; Conradsen, K.; Huttich, C.; Nielsen, A.A.; Skriver, H.; Remy, F.; Strauch, A.; Thonfeld, F.; Menz, G. Short-Term Change Detection in Wetlands Using Sentinel-1 Time Series. *Remote Sens.* 2016, 8, 795. [CrossRef]
- [12] Torbick, N.; Chowdhury, D.; Salas, W.; Qi, J.G. Monitoring Rice Agriculture across Myanmar Using Time Series Sentinel-1 Assisted by Landsat-8 and PALSAR-2. *Remote Sens.* 2017, 9, 119. [CrossRef]
- [13] Nguyen, D.B.; Wagner, W. European Rice Cropland Mapping with Sentinel-1 Data: The Mediterranean Region Case Study. *Water* 2017, 9, 392. [CrossRef]
- [14] 李苓苓, 潘耀忠, 张锦水, 宋国宝, 侯东. 支持向量机与分类后验概率空间变化向量分析法相结合的冬小麦种植面积测量方法[J]. 农业工程学报, 2010, 26(09): 210–217.
- [15] Jinfa Xu, Yue Zhu, Renhai Zhong, Zhixian Lin, Jialu Xu, Hao Jiang, Jingfeng Huang, Haifeng Li, Tao Lin, DeepCropMapping: A multi-temporal deep learning approach with improved spatial generalizability for dynamic corn and soybean mapping, *Remote Sensing of Environment*, Volume 247, 2020, 111946, ISSN 0034-4257
- [16] Shi X, Chen Z, Wang H, et al. Convolutional LSTM Network: A Machine Learning Approach for Precipitation Nowcasting[J]. MIT Press, 2015.

[17] Wang Y , Long M , Wang J , et al. PredRNN: Recurrent neural networks for predictive learning using spatiotemporal LSTMs. 2017.